35 | 解读Kubernetes三层网络方案

2018-11-12 张磊

深入剖析Kubernetes 进入课程 >



讲述:张磊

时长 19:29 大小 8.93M



你好,我是张磊。今天我和你分享的主题是:解读 Kubernetes 三层网络方案。

在上一篇文章中,我以网桥类型的 Flannel 插件为例,为你讲解了 Kubernetes 里容器网络和 CNI 插件的主要工作原理。不过,除了这种模式之外,还有一种纯三层(Pure Layer 3)网络方案非常值得你注意。其中的典型例子,莫过于 Flannel 的 host-gw 模式和 Calico 项目了。

我们先来看一下 Flannel 的 host-gw 模式。

它的工作原理非常简单,我用一张图就可以和你说清楚。为了方便叙述,接下来我会称这张图为"host-gw 示意图"。

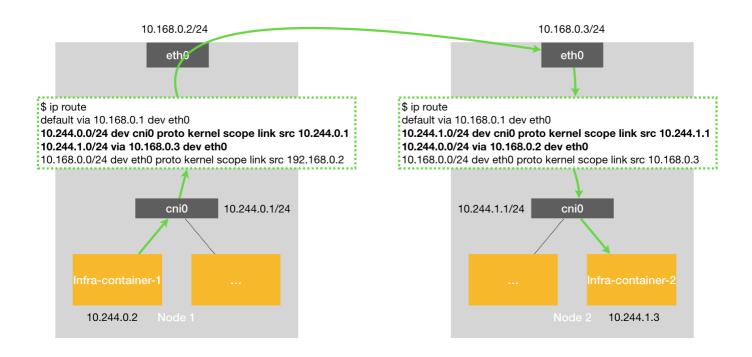


图 1 Flannel host-gw 示意图

假设现在, Node 1 上的 Infra-container-1, 要访问 Node 2 上的 Infra-container-2。

当你设置 Flannel 使用 host-gw 模式之后, flanneld 会在宿主机上创建这样一条规则,以 Node 1 为例:

```
1 $ ip route
2 ...
3 10.244.1.0/24 via 10.168.0.3 dev eth0
```

这条路由规则的含义是:

目的 IP 地址属于 10.244.1.0/24 网段的 IP 包,应该经过本机的 eth0 设备发出去(即:dev eth0);并且,它下一跳地址(next-hop)是 10.168.0.3(即:via 10.168.0.3)。

所谓下一跳地址就是:如果 IP 包从主机 A 发到主机 B,需要经过路由设备 X 的中转。那么 X 的 IP 地址就应该配置为主机 A 的下一跳地址。

而从 host-gw 示意图中我们可以看到,这个下一跳地址对应的,正是我们的目的宿主机 Node 2。

一旦配置了下一跳地址,那么接下来,当 IP 包从网络层进入链路层封装成帧的时候,eth0设备就会使用下一跳地址对应的 MAC 地址,作为该数据帧的目的 MAC 地址。显然,这个MAC 地址,正是 Node 2 的 MAC 地址。

这样,这个数据帧就会从 Node 1 通过宿主机的二层网络顺利到达 Node 2 上。

而 Node 2 的内核网络栈从二层数据帧里拿到 IP 包后,会"看到"这个 IP 包的目的 IP 地址是 10.244.1.3,即 Infra-container-2 的 IP 地址。这时候,根据 Node 2 上的路由表,该目的地址会匹配到第二条路由规则(也就是 10.244.1.0 对应的路由规则),从而进入cni0 网桥,进而进入到 Infra-container-2 当中。

可以看到, host-gw 模式的工作原理, 其实就是将每个 Flannel 子网(Flannel Subnet,比如:10.244.1.0/24)的"下一跳",设置成了该子网对应的宿主机的 IP 地址。

也就是说,这台"主机"(Host)会充当这条容器通信路径里的"网关"(Gateway)。这也正是"host-gw"的含义。

当然, Flannel 子网和主机的信息, 都是保存在 Etcd 当中的。flanneld 只需要 WACTH 这些数据的变化, 然后实时更新路由表即可。

注意:在 Kubernetes v1.7 之后,类似 Flannel、Calico 的 CNI 网络插件都是可以直接连接 Kubernetes 的 APIServer 来访问 Etcd 的,无需额外部署 Etcd 给它们使用。

而在这种模式下,容器通信的过程就免除了额外的封包和解包带来的性能损耗。根据实际的测试,host-gw 的性能损失大约在 10% 左右,而其他所有基于 VXLAN "隧道"机制的网络方案,性能损失都在 20%~30% 左右。

当然,通过上面的叙述,你也应该看到,host-gw 模式能够正常工作的核心,就在于 IP 包在封装成帧发送出去的时候,会使用路由表里的"下一跳"来设置目的 MAC 地址。这样,它就会经过二层网络到达目的宿主机。

所以说, Flannel host-gw 模式必须要求集群宿主机之间是二层连通的。

需要注意的是,宿主机之间二层不连通的情况也是广泛存在的。比如,宿主机分布在了不同的子网(VLAN)里。但是,在一个 Kubernetes 集群里,宿主机之间必须可以通过 IP 地址进行通信,也就是说至少是三层可达的。否则的话,你的集群将不满足上一篇文章中提到的宿主机之间 IP 互通的假设(Kubernetes 网络模型)。当然,"三层可达"也可以通过为几个子网设置三层转发来实现。

而在容器生态中,要说到像 Flannel host-gw 这样的三层网络方案,我们就不得不提到这个领域里的"龙头老大" Calico 项目了。

实际上, Calico 项目提供的网络解决方案, 与 Flannel 的 host-gw 模式, 几乎是完全一样的。也就是说, Calico 也会在每台宿主机上,添加一个格式如下所示的路由规则:

■ 复制代码

1 < 目的容器 IP 地址段 > via < 网关的 IP 地址 > dev eth0

■

其中, 网关的 IP 地址, 正是目的容器所在宿主机的 IP 地址。

而正如前所述,这个三层网络方案得以正常工作的核心,是为每个容器的 IP 地址,找到它所对应的、"下一跳"的**网关。**

不过,不同于 Flannel 通过 Etcd 和宿主机上的 flanneld 来维护路由信息的做法,Calico 项目使用了一个"重型武器"来自动地在整个集群中分发路由信息。

这个"重型武器",就是 BGP。

BGP 的全称是 Border Gateway Protocol,即:边界网关协议。它是一个 Linux 内核原生就支持的、专门用在大规模数据中心里维护不同的"自治系统"之间路由信息的、无中心的路由协议。

这个概念可能听起来有点儿"吓人",但实际上,我可以用一个非常简单的例子来为你讲清楚。

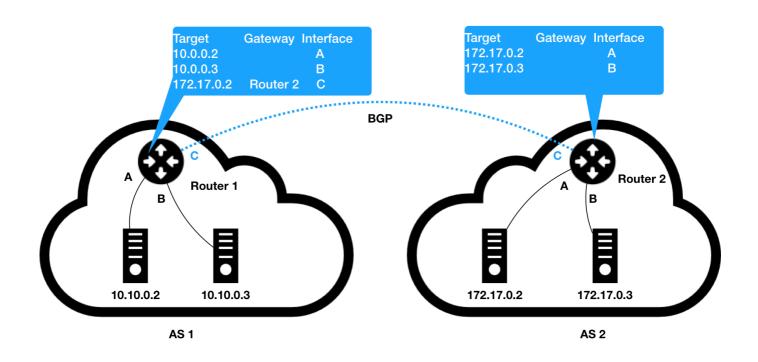


图 2 自治系统

在这个图中,我们有两个自治系统(Autonomous System,简称为 AS):AS 1 和 AS 2。而所谓的一个自治系统,指的是一个组织管辖下的所有 IP 网络和路由器的全体。你可以把它想象成一个小公司里的所有主机和路由器。在正常情况下,自治系统之间不会有任何"来往"。

但是,如果这样两个自治系统里的主机,要通过 IP 地址直接进行通信,我们就必须使用路由器把这两个自治系统连接起来。

比如, AS 1 里面的主机 10.10.0.2, 要访问 AS 2 里面的主机 172.17.0.3 的话。它发出的 IP 包, 就会先到达自治系统 AS 1 上的路由器 Router 1。

而在此时, Router 1 的路由表里,有这样一条规则,即:目的地址是 172.17.0.2 包,应该经过 Router 1 的 C接口,发往网关 Router 2 (即:自治系统 AS 2 上的路由器)。

所以 IP 包就会到达 Router 2 上, 然后经过 Router 2 的路由表,从 B 接口出来到达目的主机 172.17.0.3。

但是反过来,如果主机 172.17.0.3 要访问 10.10.0.2,那么这个 IP 包,在到达 Router 2之后,就不知道该去哪儿了。因为在 Router 2 的路由表里,并没有关于 AS 1 自治系统的任何路由规则。

所以这时候,网络管理员就应该给 Router 2 也添加一条路由规则,比如:目标地址是10.10.0.2 的 IP 包,应该经过 Router 2 的 C 接口,发往网关 Router 1。

像上面这样负责把自治系统连接在一起的路由器,我们就把它形象地称为:**边界网关**。它跟普通路由器的不同之处在于,它的路由表里拥有其他自治系统里的主机路由信息。

上面的这部分原理,相信你理解起来应该很容易。毕竟,路由器这个设备本身的主要作用,就是连诵不同的网络。

但是,你可以想象一下,假设我们现在的网络拓扑结构非常复杂,每个自治系统都有成千上万个主机、无数个路由器,甚至是由多个公司、多个网络提供商、多个自治系统组成的复合自治系统呢?

这时候,如果还要依靠人工来对边界网关的路由表进行配置和维护,那是绝对不现实的。

而这种情况下,BGP 大显身手的时刻就到了。

在使用了 BGP 之后,你可以认为,在每个边界网关上都会运行着一个小程序,它们会将各自的路由表信息,通过 TCP 传输给其他的边界网关。而其他边界网关上的这个小程序,则会对收到的这些数据进行分析,然后将需要的信息添加到自己的路由表里。

这样,图 2中 Router 2的路由表里,就会自动出现 10.10.0.2 和 10.10.0.3 对应的路由规则了。

所以说,**所谓 BGP,就是在大规模网络中实现节点路由信息共享的一种协议**。

而 BGP 的这个能力,正好可以取代 Flannel 维护主机上路由表的功能。而且,BGP 这种原生就是为大规模网络环境而实现的协议,其可靠性和可扩展性,远非 Flannel 自己的方案可比。

需要注意的是,BGP协议实际上是最复杂的一种路由协议。我在这里的讲述和所举的例子,仅是为了能够帮助你建立对BGP的感性认识,并不代表BGP真正的实现方式。

接下来,我们还是回到 Calico 项目上来。

在了解了 BGP 之后, Calico 项目的架构就非常容易理解了。它由三个部分组成:

- 1. Calico 的 CNI 插件。这是 Calico 与 Kubernetes 对接的部分。我已经在上一篇文章中,和你详细分享了 CNI 插件的工作原理,这里就不再赘述了。
- 2. Felix。它是一个 DaemonSet,负责在宿主机上插入路由规则(即:写入 Linux 内核的 FIB 转发信息库),以及维护 Calico 所需的网络设备等工作。
- 3. BIRD。它就是 BGP 的客户端,专门负责在集群里分发路由规则信息。

除了对路由信息的维护方式之外,Calico 项目与 Flannel 的 host-gw 模式的另一个不同之处,就是它不会在宿主机上创建任何网桥设备。这时候,Calico 的工作方式,可以用一幅示意图来描述,如下所示(在接下来的讲述中,我会统一用"BGP示意图"来指代它):

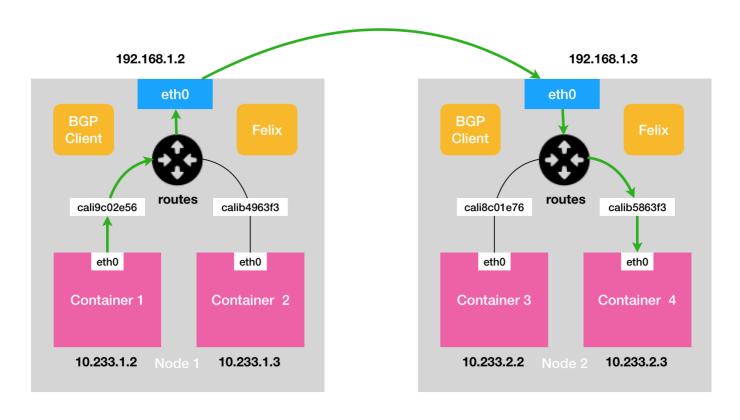


图 3 Calico 工作原理

其中的绿色实线标出的路径,就是一个 IP 包从 Node 1 上的 Container 1,到达 Node 2 上的 Container 4 的完整路径。

可以看到, Calico 的 CNI 插件会为每个容器设置一个 Veth Pair 设备, 然后把其中的一端放置在宿主机上(它的名字以 cali 前缀开头)。

此外,由于 Calico 没有使用 CNI 的网桥模式,Calico 的 CNI 插件还需要在宿主机上为每个容器的 Veth Pair 设备配置一条路由规则,用于接收传入的 IP 包。比如,宿主机 Node 2 上的 Container 4 对应的路由规则,如下所示:

1 10.233.2.3 dev cali5863f3 scope link

✓

即:发往 10.233.2.3 的 IP包,应该进入 cali5863f3 设备。

基于上述原因, Calico 项目在宿主机上设置的路由规则, 肯定要比 Flannel 项目多得多。不过, Flannel host-gw 模式使用 CNI 网桥的主要原因, 其实是为了跟 VXLAN 模式保持一致。否则的话, Flannel 就需要维护两套 CNI插件了。

有了这样的 Veth Pair 设备之后,容器发出的 IP 包就会经过 Veth Pair 设备出现在宿主机上。然后,宿主机网络栈就会根据路由规则的下一跳 IP 地址,把它们转发给正确的网关。接下来的流程就跟 Flannel host-gw 模式完全一致了。

其中,这里最核心的"下一跳"路由规则,就是由 Calico 的 Felix 进程负责维护的。这些路由规则信息,则是通过 BGP Client 也就是 BIRD 组件,使用 BGP 协议传输而来的。

而这些通过 BGP 协议传输的消息,你可以简单地理解为如下格式:

■ 复制代码

- 1 [BGP 消息]
- 2 我是宿主机 192.168.1.3
- 3 10.233.2.0/24 网段的容器都在我这里
- 4 这些容器的下一跳地址是我

不难发现, Calico 项目实际上将集群里的所有节点,都当作是边界路由器来处理,它们一起组成了一个全连通的网络,互相之间通过 BGP 协议交换路由规则。这些节点,我们称为 BGP Peer。

需要注意的是,Calico 维护的网络在默认配置下,是一个被称为"Node-to-Node Mesh"的模式。这时候,每台宿主机上的 BGP Client 都需要跟其他所有节点的 BGP Client 进行通信以便交换路由信息。但是,随着节点数量 N 的增加,这些连接的数量就会以 N²的规模快速增长,从而给集群本身的网络带来巨大的压力。

所以, Node-to-Node Mesh 模式一般推荐用在少于 100 个节点的集群里。而在更大规模的集群中, 你需要用到的是一个叫作 Route Reflector 的模式。

在这种模式下, Calico 会指定一个或者几个专门的节点, 来负责跟所有节点建立 BGP 连接从而学习到全局的路由规则。而其他节点, 只需要跟这几个专门的节点交换路由信息, 就可以获得整个集群的路由规则信息了。

这些专门的节点,就是所谓的 Route Reflector 节点,它们实际上扮演了"中间代理"的角色,从而把 BGP 连接的规模控制在 N 的数量级上。

此外,我在前面提到过,Flannel host-gw 模式最主要的限制,就是要求集群宿主机之间是二层连通的。而这个限制对于 Calico 来说,也同样存在。

举个例子,假如我们有两台处于不同子网的宿主机 Node 1 和 Node 2,对应的 IP 地址分别是 192.168.1.2 和 192.168.2.2。需要注意的是,这两台机器通过路由器实现了三层转发,所以这两个 IP 地址之间是可以相互通信的。

而我们现在的需求,还是 Container 1 要访问 Container 4。

按照我们前面的讲述, Calico 会尝试在 Node 1 上添加如下所示的一条路由规则:

■ 复制代码

1 10.233.2.0/16 via 192.168.2.2 eth0

但是,这时候问题就来了。

上面这条规则里的下一跳地址是 192.168.2.2,可是它对应的 Node 2 跟 Node 1 却根本不在一个子网里,没办法通过二层网络把 IP 包发送到下一跳地址。

在这种情况下, 你就需要为 Calico 打开 IPIP 模式。

我把这个模式下容器通信的原理,总结成了一副示意图,如下所示(接下来我会称之为: IPIP 示意图):

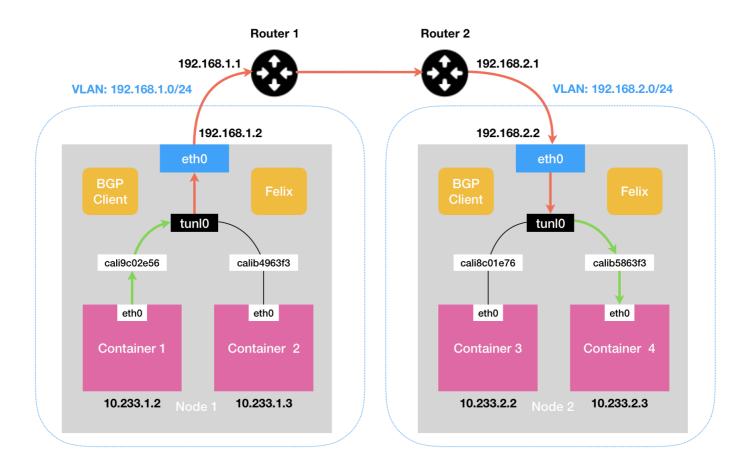


图 4 Calico IPIP 模式工作原理

在 Calico 的 IPIP 模式下, Felix 进程在 Node 1 上添加的路由规则, 会稍微不同, 如下所示:

1 10.233.2.0/24 via 192.168.2.2 tunl0

◆

可以看到,尽管这条规则的下一跳地址仍然是 Node 2 的 IP 地址,但这一次,要负责将 IP 包发出去的设备,变成了 tunl0。注意,是 T-U-N-L-0,而不是 Flannel UDP 模式使用的 T-U-N-0(tun0),这两种设备的功能是完全不一样的。

Calico 使用的这个 tunl0 设备,是一个 IP 隧道 (IP tunnel)设备。

在上面的例子中, IP 包进入 IP 隧道设备之后, 就会被 Linux 内核的 IPIP 驱动接管。IPIP 驱动会将这个 IP 包直接封装在一个宿主机网络的 IP 包中, 如下所示:

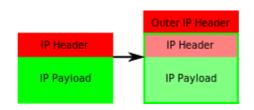


图 5 IPIP 封包方式

其中,经过封装后的新的 IP 包的目的地址(图 5 中的 Outer IP Header 部分),正是原 IP 包的下一跳地址,即 Node 2 的 IP 地址:192.168.2.2。

而原 IP 包本身,则会被直接封装成新 IP 包的 Payload。

这样,原先从容器到 Node 2 的 IP 包,就被伪装成了一个从 Node 1 到 Node 2 的 IP 包。

由于宿主机之间已经使用路由器配置了三层转发,也就是设置了宿主机之间的"下一跳"。 所以这个 IP 包在离开 Node 1 之后,就可以经过路由器,最终"跳"到 Node 2 上。

这时, Node 2 的网络内核栈会使用 IPIP 驱动进行解包,从而拿到原始的 IP 包。然后,原始 IP 包就会经过路由规则和 Veth Pair 设备到达目的容器内部。

以上,就是Calico项目主要的工作原理了。

不难看到,当 Calico 使用 IPIP 模式的时候,集群的网络性能会因为额外的封包和解包工作而下降。在实际测试中,Calico IPIP 模式与 Flannel VXLAN 模式的性能大致相当。所以,在实际使用时,如非硬性需求,我建议你将所有宿主机节点放在一个子网里,避免使用IPIP。

不过,通过上面对 Calico 工作原理的讲述,你应该能发现这样一个事实:

如果 Calico 项目能够让宿主机之间的路由设备(也就是网关),也通过 BGP 协议"学习"到 Calico 网络里的路由规则,那么从容器发出的 IP 包,不就可以通过这些设备路由到目的宿主机了么?

比如,只要在上面"IPIP示意图"中的 Node 1上,添加如下所示的一条路由规则:

■复制代码 1 10.233.2.0/24 via 192.168.1.1 eth0

然后,在 Router 1上(192.168.1.1),添加如下所示的一条路由规则:

■ 复制代码 1 10.233.2.0/24 via 192.168.2.1 eth0

那么 Container 1 发出的 IP 包,就可以通过两次"下一跳",到达 Router 2(192.168.2.1)了。以此类推,我们可以继续在 Router 2 上添加"下一条"路由,最终把 IP 包转发到 Node 2 上。

遗憾的是,上述流程虽然简单明了,但是在 Kubernetes 被广泛使用的公有云场景里,却完全不可行。

这里的原因在于:公有云环境下,宿主机之间的网关,肯定不会允许用户进行干预和设置。

当然,在大多数公有云环境下,宿主机(公有云提供的虚拟机)本身往往就是二层连通的,所以这个需求也不强烈。

不过,在私有部署的环境下,宿主机属于不同子网(VLAN)反而是更加常见的部署状态。 这时候,想办法将宿主机网关也加入到 BGP Mesh 里从而避免使用 IPIP,就成了一个非常 迫切的需求。

而在 Calico 项目中,它已经为你提供了两种将宿主机网关设置成 BGP Peer 的解决方案。

第一种方案,就是所有宿主机都跟宿主机网关建立 BGP Peer 关系。

这种方案下, Node 1 和 Node 2 就需要主动跟宿主机网关 Router 1 和 Router 2 建立 BGP 连接。从而将类似于 10.233.2.0/24 这样的路由信息同步到网关上去。

需要注意的是,这种方式下,Calico 要求宿主机网关必须支持一种叫作 Dynamic Neighbors 的 BGP 配置方式。这是因为,在常规的路由器 BGP 配置里,运维人员必须明确给出所有 BGP Peer 的 IP 地址。考虑到 Kubernetes 集群可能会有成百上千个宿主机,而且还会动态地添加和删除节点,这时候再手动管理路由器的 BGP 配置就非常麻烦了。而Dynamic Neighbors 则允许你给路由器配置一个网段,然后路由器就会自动跟该网段里的主机建立起 BGP Peer 关系。

不过,相比之下,我更愿意推荐第二种方案。

这种方案,是使用一个或多个独立组件负责搜集整个集群里的所有路由信息,然后通过 BGP协议同步给网关。而我们前面提到,在大规模集群中,Calico本身就推荐使用 Route Reflector 节点的方式进行组网。所以,这里负责跟宿主机网关进行沟通的独立组件,直接 由 Route Reflector 兼任即可。

更重要的是,这种情况下网关的 BGP Peer 个数是有限并且固定的。所以我们就可以直接把这些独立组件配置成路由器的 BGP Peer,而无需 Dynamic Neighbors 的支持。

当然,这些独立组件的工作原理也很简单:它们只需要 WATCH Etcd 里的宿主机和对应网段的变化信息,然后把这些信息通过 BGP 协议分发给网关即可。

总结

在本篇文章中,我为你详细讲述了 Fannel host-gw 模式和 Calico 这两种纯三层网络方案的工作原理。

需要注意的是,在大规模集群里,三层网络方案在宿主机上的路由规则可能会非常多,这会导致错误排查变得困难。此外,在系统故障的时候,路由规则出现重叠冲突的概率也会变大。

基于上述原因,如果是在公有云上,由于宿主机网络本身比较"直白",我一般会推荐更加简单的 Flannel host-gw 模式。

但不难看到,在私有部署环境里,Calico 项目才能够覆盖更多的场景,并为你提供更加可靠的组网方案和架构思路。

思考题

你能否能总结一下三层网络方案和"隧道模式"的异同,以及各自的优缺点?

感谢你的收听,欢迎你给我留言,也欢迎分享给更多的朋友一起阅读。



© 版权归极客邦科技所有,未经许可不得传播售卖。页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 34 | Kubernetes网络模型与CNI网络插件

下一篇 36 | 为什么说Kubernetes只有soft multi-tenancy?

精选留言 (24)





L 28

写了两篇文档:

Docker单机网络模型动手实验

https://github.com/mz1999/blog/blob/master/docs/docker-network-bridge.md Docker跨主机Overlay网络动手实验

https://github.com/mz1999/blog/blob/master/docs/docker-overlay-networks.m... 展开~



11

三层和隧道的异同:

相同之处是都实现了跨主机容器的三层互通,而且都是通过对目的 MAC 地址的操作来实现的;不同之处是三层通过配置下一条主机的路由规则来实现互通,隧道则是通过通过在 IP 包外再封装一层 MAC 包头来实现。

三层的优点:少了封包和解包的过程,性能肯定是更高的。...

展开٧



米开朗基杨

心 5

2018-11-30

写了篇关于calico开启反射路由模式的文章,希望对大家有所帮助: https://www.yangcs.net/posts/calico-rr/

展开٧



勤劳的小胖...

L 3

2018-12-29

所以三层可达,二层不可达的k8s集群不能使用Flannel host-gw模式,只能使用其他模式?



帅 2018-11-21 **ඨ** 3

老师你好,问个小白问题,怎么判断集群里的宿主机是否二层互通,或者说怎么实现二层 互通?



每日都想上...

凸 2

****工作** 2018-11-12

架设k8s集群后,对操作系统及网络知识有了一个很好的复习,感谢大神



<u></u> 2

三层网络优点: 不需要封包、拆包, 传输效率会更高; 可以设置复杂的网络策略。

隧道模式优点: 不需要在主机间的网关中维护容器路由信息, 只需要主机有三层网络的连



凸 1

2019-04-30

老师你好,问个小白问题,怎么判断集群里的宿主机是否二层互通,或者说怎么实现二层 互通?



凸 1

老师你好,根据您的文章对k8s已经有了大致了解,并且已经开始使用,但对于其中网络的相关知识还是模模糊糊(特别是您课程中网络这几章的内容),为此有了想恶补网络知识的想法,老师您对k8s相关网络知识有推荐的书籍或课程吗?

展开~



凸 1

老师好,有个1.4的K8S集群,sprincloud的微服务,怎么升级到1.10,是生产环境,有什么好的办法,谢谢

作者回复: 版本差太远了, 升级不了。。

每日都想上...

凸 1

2018-11-13

碰到一个奇怪的问题,集群中一台master节点重启后,发现docker images 镜像都被清空了一样,然后我重新pull过来,过一会又没有了,这个是哪里问题呢?

展开٧



凸

涨知识了

展开٧



Flannel host-gw模式是不是可以通过把下一跳改为网关设备的地址,来解除二层不连通不 可用的情况呢



ď

மு

请教下老师, Calico这种模式感觉就是现实中互联网的模式啊, 请问我的理解对吗



凸

2019-03-22

老师,你好,calico可以修改bird的配置选项很少,看了calico的官方文档,貌似只能支持 bird很有限的选项,这个怎么扩展呢?

展开٧



snow



2019-03-13

您好,正常路由器和交换机不在同一网段的地址也可以建立BGP邻居吧,只要保证地址互 相可达就行了。这里为什么一定要用IPIP隧道?

展开٧



2019-01-21

凸

host gw模式和ipvs的direct模式很像,都是通过二层mac直连效率最高。calico和ipvs的 ip tun模式类似,都是通过ip隧道达到跨子网通信的目的

展开~



pain

ம

2019-01-19

BGP 这种,会不会导致路由表很大

展开٧

作者回复: 有可能的



ம

老师, vxlan后端好像还有另外一种Directrouting的方式,这个跟host-gw是不是类似的。



₾

请问,如果是想要静态ip,是不是只能选择calico方案,flannel不行

作者回复: 都可以, 都要改

4